

Desarrollo de una plataforma astroinformática para la administración y análisis inteligente de datos a gran escala

“Detección y Clasificación Automática de Estructuras a Distintas Escalas Espaciales en Imágenes Astronómicas”

Mauricio Solar, Marcelo Mendoza, Jonathan Antognini,
Rodrigo Gregorio, Diego Mardones, Guillermo Cabrera,
Karim Pichara, Nelson Padilla, Ricardo Contreras,
Neil Nagar, Victor Parada.

Valparaiso, 25 de octubre de 2013

Resumen

El estudio de las estructuras en Nubes Moleculares es importante para la comunidad astronómica porque en ellas se pueden encontrar diversos objetos, los cuales requieren ser identificados y clasificados. Por este motivo, se propone el desarrollo de una aplicación automática que permita analizar imágenes y obtener una clasificación de estructuras astronómicas. El algoritmo consiste en usar algoritmos de detección de estructuras (CLUMPFIND, Dendogramas, Wavelets) y luego aplicar algoritmos de clasificación. La finalidad es construir una herramienta que quede a disposición de la comunidad y cumpla con los requerimientos de un observatorio virtual.

Palabras Claves: Minería de Datos, Astroinformática, Clasificación, Máquinas de Aprendizaje, Nubes Moleculares, Wavelets, Clump, Observatorio Virtual.

1. Resumen Ejecutivo

Este informe se enmarca en el desarrollo de los temas para el área de minería de datos en astronomía. La finalidad consiste en desarrollar e implementar herramientas que permitan entregar una mejor experiencia a los usuarios del futuro Observatorio Virtual Chileno (ChiVO).

La propuesta consiste en el desarrollo de un algoritmo para clasificar objetos analizando el tipo de dato entregado por el proyecto ALMA y la cantidad de objetos observados hasta el momento.

En base a lo anterior se genera una propuesta que aborda temáticas que son de interés dentro de los involucrados en el proyecto de la creación de ChiVO.

Índice

1. Resumen Ejecutivo	2
2. Metodología de Trabajo	4
3. Definición del Problema	5
4. Estado del Arte	6
4.1. Minería de Datos y Máquinas de Aprendizaje en Astronomía	6
4.2. Clasificación de Objetos Astronómicos	7
4.3. Nubes Moleculares	7
4.3.1. GaussClumps	8
4.3.2. ClumpFind	9
4.3.3. Dendrogramas	9
4.3.4. Wavelets	10
5. Wavelets en Astronomía	11
6. Planificación de Trabajo	12
6.1. Alcance del proyecto	12
6.1.1. Objetivo General	12
6.1.2. Objetivos Específicos	12
6.1.3. Propuesta	12
6.2. Carta Gantt	13
6.3. Explicación hitos importantes	13
Referencias	15

2. Metodología de Trabajo

Para llegar a la propuesta se llevaron a cabo reuniones con la parte técnica de las universidades involucradas en el área. Éstas reuniones se han realizado con una regularidad mensual entre los meses de Mayo y Septiembre. Se ha contado con la participación de Astrónomos e Informáticos que ha permitido la unión de las dos áreas.

Se participó en la “First La Serena School of Data Science 2013 - Applied Tools for Astronomy” en el mes de Agosto, en la cual se abordó el uso de varias herramientas para la investigación en astronomía. Aquí se pudo establecer un marco de lo que se ha realizado actualmente y los nuevos desafíos con los datos del proyecto ALMA.

La forma de trabajo que se establece es realizar una reunión mensual para analizar los avances del proyecto, en ellas participarán el área informática y su contraparte astronómica. Además, se considera la realización de reuniones de corta duración para ver tópicos específicos y resolver dudas puntuales, la periodicidad de éstas será variable.

3. Definición del Problema

El observatorio ALMA nos brindará datos en abundancia cuando comience su operación científica permanente, estos nos abrirán nuevas ventanas al estudio del universo. En parte debido a la sensibilidad a emisión de gas y polvo frío sin precedentes hasta la actualidad, y en particular debido a que los datos proveerán simultáneamente sensibilidad a:

1. Estructuras espaciales a escalas desde 0.01 hasta 1000 segundos de arco simultáneamente.
2. Una variedad de líneas espectrales simultáneas trazando estructuras de propiedades físicas y químicas muy diversas.

Esto permitirá estudiar la presencia de estructuras físicas sobre amplias escalas espaciales con diversas propiedades químicas en cada tipo de objeto. Por ejemplo, con esos datos podremos caracterizar al mismo tiempo las propiedades y distribución espacial de cúmulos de estrellas, brazos espirales, barra central, bulbo y disco en galaxias espirales cercanas. Alternativamente, podremos estudiar la distribución espacial y propiedades químicas de discos protoestelares junto a sus envolturas y vientos bipolares; simultáneamente con los núcleos de gas denso, filamentos, y nubes moleculares gigantes.

Por todo lo anterior, la detección, caracterización, y relaciones entre objetos representados por una variedad de escalas espaciales y propiedades químicas y físicas ofrece oportunidades únicas para el estudio del universo con los datos de ALMA. El desarrollo de herramientas computacionales que automaticen estas tareas es de enorme utilidad y de suma urgencia.

Finalmente, en el contexto de la creación de un observatorio virtual con los datos de ALMA, se hace necesario el desarrollo de herramientas de procesamiento y análisis de imágenes que permita hacer las labores de detección y clasificación automática de estructuras astronómicas en dichas imágenes de forma remota.

4. Estado del Arte

4.1. Minería de Datos y Máquinas de Aprendizaje en Astronomía

Esta sección está basada en el estudio realizado en [BB10] y [Bor09] .

La minería de datos puede dar un poderoso enfoque que permita abordar la explosión de datos que se genera con los nuevos proyectos astronómicos y los que están en construcción. Dentro del área de astronomía se puede definir como el proceso de convertir los datos no procesados de una observación en información útil, es decir, buscar patrones en los datos digitales y traducirlos en información relevante para la comunidad.

Los astrónomos tienen que lidiar con el enorme desafío de realizar una eficiente minería, correcta clasificación e inteligente priorización de la gran cantidad de nuevos datos. Estos datos estarán sujetos a algoritmos de máquinas de aprendizaje para clasificación de eventos, detección de datos aislados, caracterización de objetos y nuevos descubrimientos.

Algunas de las ventajas que proporciona esta visión son: obtener cualquier tipo de dato, simplicidad, reconocimiento de patrones, enfoque complementario (Incluso cuando el enfoque no produce una mejoría sustancial, todavía actúa como un importante método complementario de análisis de datos).

Para comenzar en esta área de investigación es necesario conocer los desafíos que surgen en Minería de Datos [Bor13]:

1. Desarrollo de metodologías de análisis para descubrimiento y caracterización de comportamiento emergente en sistemas complejos.
2. Desarrollo de métodos eficientes para el análisis estadístico de conjunto de datos heterogéneos y de gran escala.
3. Desarrollo riguroso, pero computacionalmente factible, de métodos para la reducción dimensional de datos.
4. Desarrollo de técnicas fiables para deducir la información de datos y fuentes de conocimiento que son de alta dimensión y heterogénea en naturaleza y calidad.
5. Re-ingeniería de máquinas de aprendizaje y algoritmos estadísticos para escalarlos con el tamaño del conjunto de datos.
6. Desarrollo de algoritmos para la detección de “Outlier”, anomalías y no estacionalidad en el flujo de datos.
7. Desarrollo de nueva matemática para la extracción de nuevas visiones de datos complejos.
8. Caracterización de áreas de interés en datos masivos variantes en el tiempo, identificación de áreas en conjunto de datos masivos los que los científicos pueden investigar en profundidad.

La minería de datos astronómicos es el análisis exploratorio de datos (EDA)¹ que utiliza algoritmos de máquinas de aprendizaje para explorar datos a través de minería de datos, detección sorpresa y descubrimiento científico en datos de gran escala.

Estas Máquinas de aprendizaje se clasifican según sus usos:

- **Caracterizar los Datos:** Aprendizaje no supervisado, clustering, descubrimiento de clases.
- **Asignación de Etiquetas de Clases:** Aprendizaje supervisado, clasificación.
- **Descubrir lo Desconocido:** Aprendizaje semi-supervisado, detección de “outlier/novelty”

La amplia variedad de métodos disponibles se reflejan en una amplia red de técnicas de matemáticas aplicadas; que incluyen matemática discreta, álgebra lineal, combinatoria, geometría, métodos de grafos, etc. El interés de esta trabajo es en los métodos de clasificación (asignación de etiquetas de clases a nuevos datos usando los grupos y clases ya conocidos). Los algoritmos más comunes para clasificación incluyen clasificación bayesiana, árboles de decisión, redes neuronales artificiales, regresión, máquinas de soporte vectorial, modelos de Markov y K-vecinos más cercanos.

4.2. Clasificación de Objetos Astronómicos

El explosivo crecimiento de los datos astronómicos en cantidad, y accesibilidad ha generado un gran interés en las tareas de análisis más comunes en astronomía como son: Visualización de Datos, Agrupamiento y Clasificación de Datos [SCDV⁺05].

Los algoritmos de Máquinas de Aprendizaje y Minería de Datos tienen un comportamiento similar al proceso de asignación de clases a objetos en Astronomía: descubrimiento de clases, descubrir reglas para las diferentes clases, construir muestras de entrenamiento para refinar las reglas, asignación de nuevos objetos a clases conocidas usando nuevas mediciones de datos científicos para esos objetos.

Las Redes Neuronales Artificiales (RNA) se han usado para clasificar galaxias y estrellas [CMHF01]. Se establecen dos tipos de enfoques: clasificación parametrizada, donde un conjunto de características se extraen de un objeto que será clasificado; “modo de imagen directa”, los objetos recortados de la imagen de entrada y estas micro imágenes son usadas como vector de entrada. Otro enfoque es la clasificación morfológica [GL02, BLF⁺03], la cual consiste en separarlas según la secuencia de Hubble [Hub26]. Además, las RNA se han utilizado en la determinación del “Redshift” fotométrico estimado [OLC⁺08], el cual es usado como estimador de distancia para un gran número de galaxias.

4.3. Nubes Moleculares

Las nubes moleculares son las cunas de estrellas, están formadas de gas y polvo. El gas es predominantemente hidrógeno molecular H_2 , aunque contienen además CO , H_2O , y moléculas más complejas tales como alcoholes y formaldeídos. Las moléculas más abundantes después del H_2 es el monóxido de carbono (CO), que es fácilmente observable en ondas milimétricas.

¹Exploratory Data Analysis

El gas y polvo al interior de nubes moleculares gigantes se distribuye en una componente difusa al interior del cual hay filamentos de gas mas denso en diversas direcciones, con composición química y propiedades físicas definidas. Estos filamentos a su vez se dividen o intersectan formando núcleos de gas denso, al interior de los cuales se generan discos de acreción donde nacen las protoestrellas (ver [BT07, KE12]).

Algunos algoritmos utilizados en astronomía para identificar objetos dentro de las nubes son nombrados a continuación.

4.3.1. GaussClumps

El algoritmo GaussClumps [SG90] consiste en ajustar perfiles Gaussiano a los picos más brillantes en los datos. Esto se puede realizar en dos o tres dimensiones (ángulo, frecuencia, como los cubos de datos de ALMA). Los ajustes se realizan progresivamente desde los picos mas brillantes hasta los de menor brillo. Al ajustar cada Gaussiana esta se agrega al catálogo de salida., luego se resta para ajustar la siguiente, hasta descomponer la imagen inicial en una superposicion de Gaussianas en distintas posiciones, con distinta orientacion, tamaño, e intensidad. La suma de las componentes Gaussianas reproduce la imagen original mas un ruido, que idealmente debe ser normal y homogéneo a lo largo de la imagen (ver figura 1).

En este algoritmo, los clumps pueden superponerse y por esta razón los píxeles de entrada no pueden ser asignados a un solo clump.

Cualquier componente de la varianza de entrada se utiliza para escalar el peso asociado a cada píxel cuando se realiza el ajuste de Gauss. Sus principales parámetros son el tamaño mínimo de los clumps y el umbral para el criterio de término.




Figura 1: Un ejemplo de un modelo en 2D de gas molecular

4.3.2. ClumpFind

ClumpFind fue desarrollado por J. Williams [WdB94]. En este algoritmo se parte del pico más brillante de la imagen (primer clump) y todos los píxeles se van asociando al mismo clump bajando gradualmente en intensidad hasta que aparezca un segundo pico aislado del primero. Este proceso continua asignando todos los píxeles de la imagen original al clump más cercano. Los clumps tienen así formas arbitrarias, y se encuentran separados por puntos silla en caso de estar conectados entre sí, o por el cielo si están separados (ver figura 2).

Con este algoritmo la estructura de las nubes es dividida en una serie de clumps disjuntos espacialmente, de modo que colectivamente reproducen la imagen original incluyendo el ruido del cielo. Así, el algoritmo es equivalente a tomar una maqueta de la imagen original y dividirla en la dirección perpendicular al cielo, como con un cortador de galletas donde cada galleta tiene una forma distinta y todas encajan perfectamente como piezas de un puzzle para reproducir la maqueta original.




Figura 2: Un ejemplo de clumps encontrados con el algoritmo ClumpFind

4.3.3. Dendrogramas

Rosolowsky [RPKG08] utiliza de dendrogramas en la representación de las características esenciales de la estructura jerárquica de las “iso-superficies” para cubos de datos de línea molecular. Si el algoritmo clumpfind divide un mapa de contornos en piezas de un puzzle, la idea detrás de los dendrogramas es dividir el puzzle en una colección de capas distintas como una masa de hoja, es decir, como si cada contorno de un mapa geológico representa un objeto distinto.

Es claro que la suma de los objetos de nuevo, reproduce idénticamente la imagen original. A diferencia de los métodos anteriores, los dendrogramas ordenan las estructuras encontradas de forma jerárquica en árbol – ramas – hojas. Dicho ordenamiento define relaciones físicas entre los distintos objetos catalogados (ver figura 3).




Figura 3: Un ejemplo de clumps encontrados con Dendrogramas

4.3.4. Wavelets

Las wavelets son un tipo especial de transformada de Fourier que representa una señal en términos de versiones trasladadas y dilatadas de una wavelet madre.

Alves [ALL07] utiliza la transformada de wavelet de una imagen para primero identificar y luego reconstruir los núcleos densos. Se menciona que los métodos tradicionales basados en umbrales no tienen buenos resultados, por eso es que se recurren a un algoritmo creado por Vandame(2006, private comm.) el cual consiste en usar la transformada de Wavelets sobre una imagen (ver figura 4).




Figura 4: Un ejemplo de núcleos densos encontrados por medio del uso de Wavelets

La identificación de objetos en el espacio de Wavelets consiste en aislar estructuras dada una escala. Las estructuras en escalas consecutivas se conectan si el máximo local de la primera está dentro de la estructura de la siguiente. Luego se construye una distribución en 3D de las estructuras más significantes.

5. Wavelets en Astronomía

La Transformada de Wavelet se usa para el análisis local de señales no estacionarias y de rápida transitoriedad, y mapea la señal en una representación de tiempo-escala. El aspecto temporal de las señales es preservado. La diferencia con la Transformada de Fourier está en que la Transformada Wavelet provee análisis de multiresolución con ventanas dilatadas. El análisis de las frecuencias de mayor rango se realiza usando ventanas angostas y el análisis de las frecuencias de menor rango se hace utilizando ventanas anchas [She96].

Las Wavelets, funciones bases de la Transformada Wavelet, son generadas a partir de una función Wavelet básica, mediante traslaciones y dilataciones. Estas funciones permiten reconstruir la señal original a través de la Transformada Wavelet inversa.

La Transformada Wavelet no es solamente local en tiempo, sino también en frecuencia.

Dentro de los usos de esta poderosa herramienta podemos nombrar, además del análisis local de señales no estacionarias, el análisis de señales electrocardiográficas, sísmicas, de sonido, de radar, así como también

es utilizada para la compresión y procesamiento de imágenes y reconocimiento de patrones. En [JMR01] se dan ejemplos de aplicaciones de las Wavelets en astronomía.

En el libro de Starck y Murtagh [SM06] se hace una revisión a las distintas aplicaciones de las Wavelets en astronomía. Además, en el apéndice se entrega una descripción del algoritmo para la implementación de una transformada de Wavelets discreta conocida como A Trous.

6. Planificación de Trabajo

6.1. Alcance del proyecto

6.1.1. Objetivo General

Generar una herramienta de detección y clasificación automática de estructuras astronómicas en imágenes astronómicas sobre una variedad de escalas espaciales.

6.1.2. Objetivos Específicos

1. Detectar y clasificar estructuras en un amplio rango de escalas espaciales en imágenes obtenidas con el radiotelescopio ALMA, utilizando técnicas de multi-resolución a través de una descomposición con transformadas de wavelets.
2. Relacionar espacialmente las estructuras encontradas en cada imagen en relaciones de tipo y parentesco.
3. Detectar y clasificar estructuras en un amplio rango de escalas espaciales en un rango de luz de distinta frecuencia en cubos de datos obtenidas con el radiotelescopio ALMA, utilizando técnicas de multi-resolución a través de una descomposición con transformadas de wavelets. Las frecuencias de la luz corresponden a distintas velocidades radiales de acuerdo al efecto Doppler.
4. Realizar la clasificación anterior sobre una variedad de líneas espectrales observadas con ALMA en un mismo objeto astronómico y buscar relaciones entre ellas.
5. Implementar éstos algoritmos sobre la plataforma del observatorio virtual ChiVO.
6. Diseñar algoritmos básicos de minería de datos aplicables al total de los datos de ALMA (o subconjuntos) accesibles a través de ChiVO.

6.1.3. Propuesta

La propuesta consiste en desarrollar un algoritmo que permita identificar y clasificar estructuras astronómicas a diferentes escalas, para ellos se hará uso de la transformada de Wavelets. Se busca generar un conjunto de imágenes con escalas distintas y luego aplicar algún algoritmo del tipo CLUMPFIND para identificar objetos en cada imagen. Al unir todas las imágenes generadas se debiese obtener el conjunto total de estructuras que contiene la imagen que se esta analizando.

A partir de las estructuras encontradas en el paso anterior se prosigue con la aplicación de un algoritmo de clasificación que permita reconocer a que tipo de objeto pertenecen las estructuras encontradas. El área astronómica determinará que criterios se considerarán para clasificar estos objetos.

Como parte final, se espera generar una aplicación empaquetada que se pueda utilizar de forma “standalone” o pueda ser incluida como un módulo dentro del software CASA o estar dentro de ChiVO. De esta forma la herramienta generada estará al alcance de la comunidad y además debe cumplir con los requerimientos de un Observatorio Virtual.

En relación a lo anterior se eligió el uso del lenguaje de programación Python para el desarrollo del proyecto. Con este lenguaje es posible instalar bibliotecas en CASA de forma fácil y limpia.

6.2. Carta Gantt

Inicio	Termino	Actividad
09-09-2013	04-10-2013	Formulación del Proyecto
07-10-2013	01-11-2013	Implementación de algoritmo para Wavelets en imágenes 2D.
04-11-2013	29-11-2013	Implementación de algoritmos de detección de objetos en imágenes 2D
02-12-2013	03-01-2014	Aplicación de métodos estadísticos a los objetos encontrados en 2D
06-01-2014	31-01-2014	Integración de algoritmos 2D a software
03-02-2014	02-05-2014	Aplicación de mejoras a algoritmos en imágenes 2D implementados.
03-03-2014	02-05-2014	Implementación de algoritmo wavelets en cubos 3D
05-05-2014	29-06-2014	Implementación de algoritmos de detección de objetos en imágenes 3D
01-07-2014	01-08-2014	Aplicación de métodos estadísticos a los objetos encontrados en 3D
04-08-2014	03-10-2014	Integración del proyecto en ChiVO.
04-08-2014	02-11-2014	Implementación de nuevos algoritmos 3D
04-08-2014	02-11-2014	Integración de los nuevos algoritmos 3D al software
03-11-2014	05-12-2014	Pruebas de funcionamiento del sistema
05-12-2014	31-03-2015	Validación del Proyecto
05-12-2014	31-03-2015	Análisis de factibilidad de uso sobre el conjunto de archivos de ALMA

Cuadro 1: Carta Gantt del Proyecto

6.3. Explicación hitos importantes

Formulación del Proyecto Definición de objetivos específicos y carta Gantt del problema.

Aplicación de métodos estadísticos a los objetos encontrados en 2D Se busca comprobar que efectivamente las relaciones entre estructuras encontradas, a través de los algoritmos de descomposición basados en wavelets, y listas de objetos; se recuperará la información original de la imagen y se reproducen resultados obtenidos previamente.

Integración de algoritmos 2D a software implementación de algoritmos en una aplicación independiente y/o al interior del software CASA.

Aplicación de Mejoras a algoritmos en 2D Exploración de ventajas del algoritmo original de clumpfind comparado con Csar, Gaussclumps, SExtractor, u otros algoritmos de extracción de fuentes en imágenes 2D.

Integración del Proyecto en ChiVO Implementación de algoritmos a través de las herramientas desarrolladas para ChiVO, directamente en los archivos de datos públicos de ALMA.

Validación del Proyecto Publicación de algoritmos en modo beta dentro de ChiVO, buscando feedback de parte de la comunidad de astrónomos tanto chilenos como internacionales y reproducción de resultados en una variedad de imágenes de prueba.

Análisis de factibilidad de uso sobre el conjunto de archivos de ALMA Se analizará factibilidad del uso de estos algoritmos junto con herramientas de minería de datos sobre el conjunto completo de datos del archivo de ALMA, o subconjuntos de éste.

Referencias

- [ALL07] J. Alves, M. Lombardi, and C. J. Lada. The mass function of dense molecular cores and the origin of the IMF. *Astronomy & Astrophysics*, 462:L17–L21, January 2007.
- [BB10] N. M. Ball and R. J. Brunner. Data Mining and Machine Learning in Astronomy. *International Journal of Modern Physics D*, 19:1049–1106, 2010.
- [BLF⁺03] N M Ball, J Loveday, M Fukugita, O Nakamura, S Okamura, J Brinkmann, and R J Brunner. Galaxy types in the sloan digital sky survey using supervised artificial neural networks. *Mon. Not. R. Astron. Soc.*, 348(astro-ph/0306390):1038. 9 p, Jun 2003.
- [Bor09] K. Borne. Scientific Data Mining in Astronomy. *ArXiv e-prints*, November 2009.
- [Bor13] Kirk Borne. Virtual observatories, data mining, and astroinformatics. In TerryD. Oswalt and HowardE. Bond, editors, *Planets, Stars and Stellar Systems*, pages 403–443. Springer Netherlands, 2013.
- [BT07] E. A. Bergin and M. Tafalla. Cold Dark Clouds: The Initial Conditions for Star Formation. *Annual Review of Astronomy & Astrophysics*, 45:339–396, September 2007.
- [CMHF01] Filippo Cortiglioni, Petri Mähönen, Pasi Hakala, and Tapio Frantti. Automated star-galaxy discrimination for large surveys. *The Astrophysical Journal*, 556(2):937, 2001.
- [GL02] ShaikatN. Goderya and ShawnM. Lolling. Morphological classification of galaxies using computer vision and artificial neural networks: A computational scheme. *Astrophysics and Space Science*, 279(4):377–387, 2002.
- [Hub26] E. P. Hubble. Extragalactic nebulae. *apj*, 64:321–369, December 1926.
- [JMR01] Stéphane Jaffard, Yves Meyer, and Robert D. Ryan. *12. Wavelets and Astronomy*, chapter 12, pages 187–201. Society for Industrial and Applied Mathematics, 2001.
- [KE12] R. C. Kennicutt and N. J. Evans. Star Formation in the Milky Way and Nearby Galaxies. *Annual Review of Astronomy & Astrophysics*, 50:531–608, September 2012.
- [OLC⁺08] H. Oyaizu, M. Lima, C. E. Cunha, H. Lin, J. Frieman, and E. S. Sheldon. A Galaxy Photometric Redshift Catalog for the Sloan Digital Sky Survey Data Release 6. *apj*, 674:768–783, February 2008.
- [RPKG08] E. W. Rosolowsky, J. E. Pineda, J. Kauffmann, and A. A. Goodman. Structural Analysis of Molecular Clouds: Dendrograms. *The Astrophysical Journal*, 679:1338–1351, June 2008.
- [SCDV⁺05] A. Staiano, A. Ciaramella, L. De Vinco, C. Donalek, G. Longo, G. Raiconi, R. Tagliaferri, R. Amato, C. Del Mondo, G. Mangano, and G. Miele. Visualization, clustering and classification of multidimensional astronomical data. In *Computer Architecture for Machine Perception, 2005. CAMP 2005. Proceedings. Seventh International Workshop on*, pages 141–146, 2005.

- [SG90] J. Stutzki and R. Guesten. High spatial resolution isotopic CO and CS observations of M17 SW - The clumpy structure of the molecular cloud core. *The Astrophysical Journal, Part 1*, 356:513–533, June 1990.
- [She96] Yunlong Sheng. Wavelet transform. *The transforms and applications handbook*, pages 747–827, 1996.
- [SM06] J.-L. Starck and F. Murtagh. *Astronomical Image and Data Analysis*. Springer, 2nd edition, 2006.
- [WdB94] J. P. Williams, E. J. de Geus, and L. Blitz. Determining structure in molecular clouds. *The Astrophysical Journal*, 428:693–712, June 1994.